

Exercice 1

```
1. distX = as.matrix(X)
   distX = distX ^2

2. Mthode 1
   XC = scale(X, scale=T)
   W = XC\%*\%t(XC)

   Mthode 2
   QN = diag(nrow(X)) - matrix(1, nrow(X), nrow(X))/nrow(X)
   W = -1/2*QN\%*\%distX\%*\%QN

3. Pour vrifier si elle est dfinie semi-positive, il suffit de vrifier que les valeurs propres
   eigen(W)

4. L = eigen(W)$values
   L = diag(nrow(X))*L

   V = eigen(W)$vectors

5. C = V\%*\%sqrt(L)
   pas oublier de retirer les NaN

   plot(C)
   idem biplot(princomp(X))
```

Exercice 2

```
m = as.vector(mutation)
b = cmdscale(mutation, 2, T)
c = as.vector(dist(b$points))
plot(b,c) problme mais on est pas loin
qualit calculer avec les valeurs propres b[,1]$eigen etc... / sum

on refait de mme avec cmdscale(mutation, 3, T) jusqu' 5
```

Exercice 3

```
library(cluster) clusplot
```

```

iris, fig=TRUE) = par(mfrow=c(1,3)) clusplot(iris, res2cluster) res3 =
kmeans(iris, 3) clusplot(iris, res3cluster) res4 = kmeans(iris, 4) clusplot(iris,
res4cluster)@

```

Figure 1: Visualisation de kmeans avec 2, 3 et 4 partitions

Iris

Question 1 - Diffrents nombres de partition

Premièrement, nous remarquons que les partitions n'ont pas toutes le même nombre d'éléments. Ensuite, elle varie suivant le nombre de partitions. En effet, nous pourrions penser qu'entre eux 3 et 4 partitions, l'ajout d'une partition subdiviserait une partition déjà existante. Comme le montrent les graphes ci-dessous cela n'est pas le cas. En effet les 3 partitions de droite pour K=4 ne sont pas contenues dans entièrement 2 partitions de K=3. Toutes les partitions sont redéfinies chaque fois que nous augmentons le nombre.

Question 2 - Stabilité des partitions

De plus, même pour un même K, dans notre cas k=3, les partitions peuvent changer. Ici, nous avons deux cas différents avec des inerties de classes de 143 ou 78.9. Cela est dû au choix aléatoire des centres au début de l'algorithme.

Question 3 - Nombre de partitions optimales

```

$for(j in 2:10){
  for(i in 1:100){
    test[j, i] = kmeans(iris, j)$tot.withinss
  }
}$
apply(test, 2, min)

```

La solution optimale semble être en 3 classes. Pourtant celle-ci n'est pas flagrante avec le tableau des minimums des inerties. La méthode du coude ne fonctionne pas très bien, elle ne fait pas apparaître de coude. Le minimum d'inertie de fait que diminuer en fonction du nombre de classes. Une solution serait d'analyser un grand nombre de classes par le nombre d'individus présents dans la classe.

Question 4 - Partitions réelles

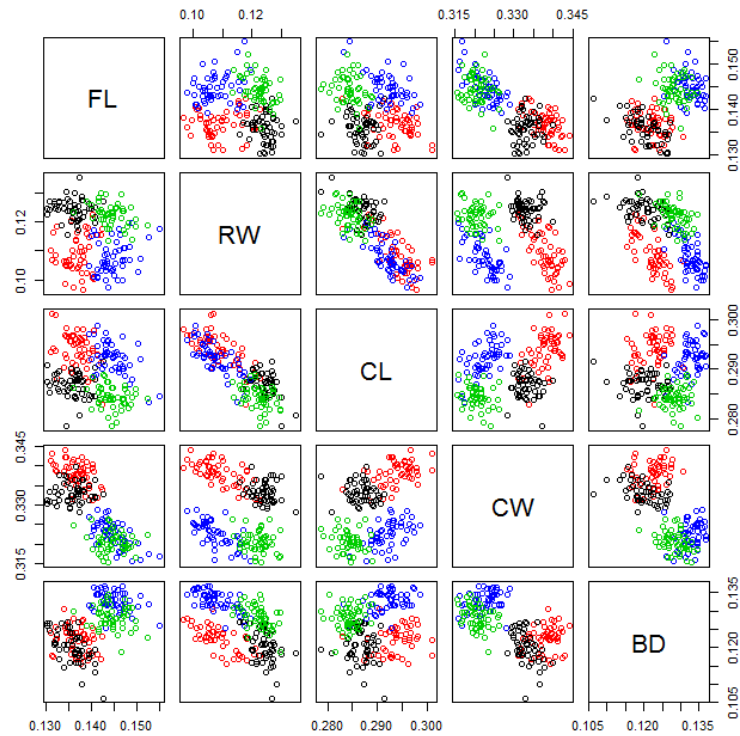
Crabs

```

library(MASS)
data(crabs)
crabsquant <- crabs[,4:8]
crabsquant <- crabsquant/matrix(rep(crabsquant[,4],dim(crabsquant)[2]),
nrow=dim(crabsquant)[1],byrow=F)

```

```
clusplot(crabsquant, kmeans(crabsquant, 4)$cluster)
plot(crabsquant, col =kmeans(crabsquant, 4)$cluster)
```



Mutations

```
res = kmeans(mutations2, 2)
plot(cmdscale(mutations), col=res$cluster)
```

Avec 3 vert au milieu des noirs

4 cluster seulement un point dans le dernier

tableau de contingence pour comparer les partitions `table(res$cluster, res2$cluster)`